

Trabalho de Redes Neurais

Professor: Leonardo Mendonza

Nome: Mayta Soares Custodio

Matrícula: 192.671.147


Turma: 2019.2

Premissas:

A base apresentada é de pessoas mortas por doenças pulmonares na Inglaterra, a ideia é prever em um período de tempo com redes LSTM. Por favor, rodem o código com a base de dados, vejam os resultados e façam as seguintes mudanças.

- 1- Mudem o otimizador de adam para sgd dentro da configuração da rede e veja os resultados de RMSE.

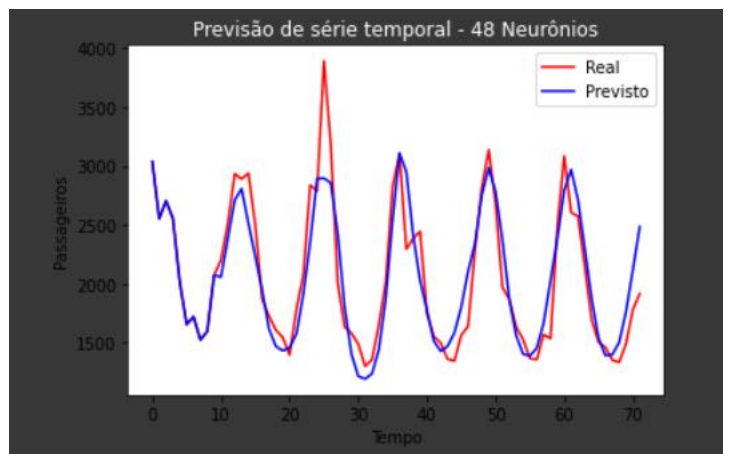
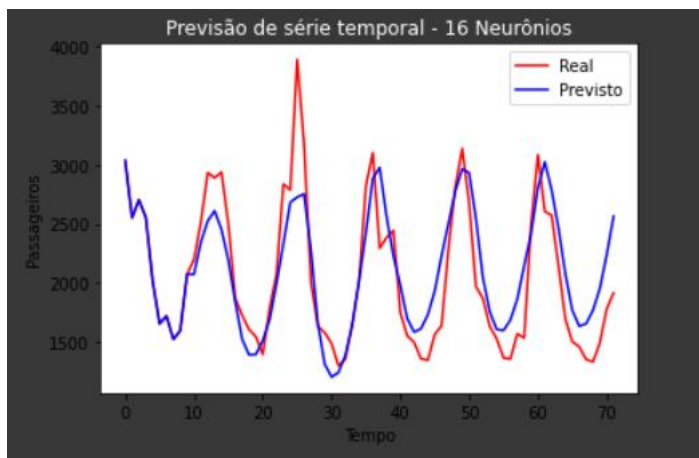
Configurações			Métricas de Avaliação		
Nº neurônios	Otimizador	LSTM(Camadas)	RMSE	MSE	MAPE
100	Adam	1	221.5253056202 255	49073.46103013431	9.070578986271373 %
100	SGD	1	548.2300546458 508	300556.1928169926	28.143526657389906 %



Pelos números da tabela acima e pela comparação dos gráficos de previsão da série temporal, vemos que a previsão do modelo SGD diferencia drasticamente da projetada pelo otimizador Adam, que prevê com maior precisão. Ficamos então com esse otimizador, pois é a melhor configuração.

- 2- Voltando a configuração inicial mude o numero de neurônios da camada LSTM, primeiro para 16 e depois para 48 e veja o resultado do RMSE.


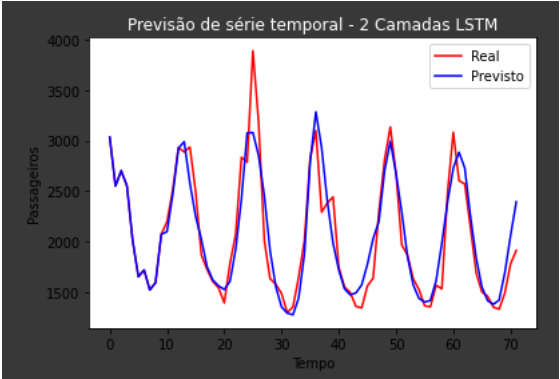
Configurações			Métricas de Avaliação		
Nº neurônios	Otimizador	LSTM(Camadas)	RMSE	MSE	MAPE
16	Adam	1	383.7212609022 9966	147242.00606845072	20.46142711174349 %
48	Adam	1	264.3585262483 77	69885.43040021385	11.362287449281624 %
100	Adam	1	221.5253056202 255	49073.46103013431	9.070578986271373 %



Realizando a comparação entre os valores de 16 e 48, vemos que quanto maior o número de neurônios, melhor. Entre o formato de 100 neurônio e mudanças propostas de 16 e 48, vemos a formação original (100) possui melhores números e desempenhos, ficamos então com esse valor na primeira camada.

3-coloque uma segunda camada LSTM e veja o resultado do RMSE


Nº neurônios							
Camada 1	Camada 2	Camada 3	Épocas	Otimizador	RMSE	MSE	MAPE
100	X	X	250	Adam	221.5253056202255	49073.46103013431	9.070578986271373 %
100	80	X	250	Adam	228.62643001815897	52270.04450284814	9.306655119343914 %
100	80	50	250	Adam	219.92699272796375	52270.04450284814	9.300703764091569 %



Comparando apenas a inclusão da segunda e terceira camada, não se vê uma grande alteração, porém proporemos abaixo, mais mudanças entre números de camadas combinadas à épocas de treinamentos distintas para verificar melhor as alterações.

4- Mude por dois valores que você ache convenientes as épocas de treinamento e veja o resultado do RMSE.

Nº neurônios					Métricas de Avaliação		
Camada 1	Camada 2	Camada 3	Épocas	Otimizador	RMSE	MSE	MAPE
100	X	X	250	Adam	221.5253056202255	49073.46103013431	9.070578986271373 %
100	X	X	150	Adam	337.004540858958	113572.06055955713	15.58017118209676 %
100	X	X	300	Adam	210.03068152919124	44112.887183616556	8.385945947777422 %




Nesse teste pudemos verificar que mais épocas de treinamento acima do número inicial (250), ajudam ao modelo a ter melhor resultado. As próximas tentativas serão nessa direção.

Antes de indicar a melhor configuração, realizei uma série de testes com variação de camadas e épocas.

Nº neurônios				Métricas de Avaliação			
Camada 1	Camada 2	Camada 3	Épocas	RMSE	MSE	MAPE	Coefficiente de Determinação
100	X	X	250	234.97	55214.17	9.49	0.8160
100	X	X	500	192.77	37160.45	7.24	0,8762
100	X	X	600	208.77	43585.90	7.24	0.8547
100	80	X	500	215.68	46520.84	8.85	0.8450
100	80	X	600	205.16	42093.53	8.42	0.8597
100	80	50	500	222.44	49481.32	9.94	0.8351
100	80	50	600	190.54	36307.79	8.55	0.8790
100	80	50	250	177.20	31401.21	7.36	0.8953
100	80	50	300	218.40	47699.25	8.27	0.8410
100	80	50	200	237.24	56283.60	9.12	0.8124
100	80	X	250	280.33	78587.80	12.77	0.7381

5- Com as mudanças feitas proponha sua configuração ideal.

Após as diversas alterações e tentativas entre camadas, número de neurônios, otimizador e épocas, o melhor resultado apresentado foi o modelo com: 3 camadas, 100,80,50 neurônios em cada respectivamente, otimizador Adam e 250 épocas, retornando valor de RMSE de 177.20, MSE 31401, MAPE 7.36, e adicionei o coeficiente de determinação para melhor pesar o desempenho, tendo este em 0.8953 (89,53). Essa configuração que apresentou o modelo ideal.



Parte 4 - Métricas de avaliação

```
[ ] import math
from sklearn.metrics import mean_squared_error
rmse = math.sqrt(mean_squared_error(test_pul, predicted))
print('RMSE: ', rmse)

RMSE: 177.20387020770562

[ ] mse = mean_squared_error(test_pul, predicted)
print('MSE: ',mse)

MSE: 31401.21161658938

[ ] mape = np.mean(np.abs((test_pul - predicted) / test_pul)) * 100
print('MAPE: ',mape, '%')

MAPE: 7.360768916102822 %

[ ] # Calculando o coeficiente de determinação

from sklearn.metrics import r2_score
r2_score(test_pul, predicted)

0.8953906944620914
```

